深度学习课程设计技术报告

基于 ChnSentiCorp 的中文情感分类对比

学号：52612048025　　姓名：马陈奕

课程：深度学习课程设计（2026-秋季）

代码仓库：https://github.com/machenyi170/dl-course-sentiment

一、研究问题与动机

这次作业我想做一件能完整跑通的小事：给中文酒店评论判正面还是负面。选 ChnSentiCorp，是因为数据现成、规模适中，CPU 也能训完。我不打算发明新模型，主要对比三种常见路线——传统机器学习、BiLSTM、以及一个小的中文预训练模型——看它们在同一划分下差多少，差距大概出在哪里。

具体就是：实现 TF-IDF+线性 SVM、BiLSTM、hfl/rbt3 三种方法；统一用 Accuracy 和 Macro-F1；各做一点消融；最后把错例翻一翻，写成这份报告，代码也能复现。

二、数据与实验环境

2.1 数据集

数据用的是 HuggingFace 上的 lansinuote/ChnSentiCorp，酒店评论二分类。直接用官方划分：训练 9600、验证 1200、测试 1200；0 负面、1 正面，两边差不多均衡。评论长短不一，我没重新标数据，只去掉空文本，再按各方法需要做分词或编码。

2.2 环境与评价指标

实验环境是 Linux + CPU（Python 3.13，PyTorch CPU 版），主要用到 scikit-learn、jieba、Transformers、datasets 和画图库。指标统一报 Accuracy 和 Macro-F1；神经网络按验证集 Macro-F1 留最好一轮，再到测试集上看最终数。随机种子固定 42。

三、方法

3.1 TF-IDF + Linear SVM

先用 jieba 分词，再做成 TF-IDF（最多 3 万维，1–2 gram，min_df=2），上面接 LinearSVC（C=1.0）。这个方法写起来快、跑得也快，当作强基线：很多评论里“脏”“差”“满意”这类词本身就很有信号，词袋未必吃亏。

3.2 BiLSTM

BiLSTM 按词建模：词表只保留训练集里出现不少于 2 次的词，句子截到 128。词向量 100 维，单层双向 LSTM，隐层 128，把两端最后状态拼起来再分类。Adam + 交叉熵，训练 6 个 epoch，顺带做梯度裁剪。消融是：词向量跟着训，还是冻住随机初始化。大的中文预训练词向量这边不好下全，所以用冻/不冻嵌入来看嵌入层到底有没有帮上忙。

3.3 预训练中文编码器 + 分类头

预训练这边用了比较小的中文模型 hfl/rbt3（3 层，CPU 还能动），最大长度 128，batch 16。两种设置：一是编码器全冻住，只训上面的分类头；二是放开最后两层，用小一点的学习率微调。主要想对比“当特征用”和“稍微改一改适配任务”差多少，也符合这门课不要求硬训大模型的要求。

四、设计与实现要点

代码按脚本拆开了：prepare_data.py 下数据；train_svm / train_bilstm / train_bert 各自训练；plot_results.py 出图。指标都写进 JSON/CSV，不靠口头估。三类方法用同一套官方划分；BiLSTM 用 pack_padded_sequence 处理长短不一；BERT 按验证 Macro-F1 存最好权重；脚本都能在 CPU 上跑。

五、实验结果

验证集和测试集的主要结果见表 1，都是实际跑出来的数。

方法	验证 Acc	验证 Macro-F1	测试 Acc	测试 Macro-F1
TF-IDF+SVM	90.58%	90.57%	91.50%	91.50%
BiLSTM-随机词	86.08%	86.08%	86.67%	86.63%

向量				
BiLSTM-冻结词向量	83.50%	83.50%	84.33%	84.30%
BERT-冻结编码器	80.58%	80.55%	79.92%	79.71%
BERT-微调末两层	89.25%	89.25%	90.00%	89.99%

表 1 各方法验证/测试性能对比

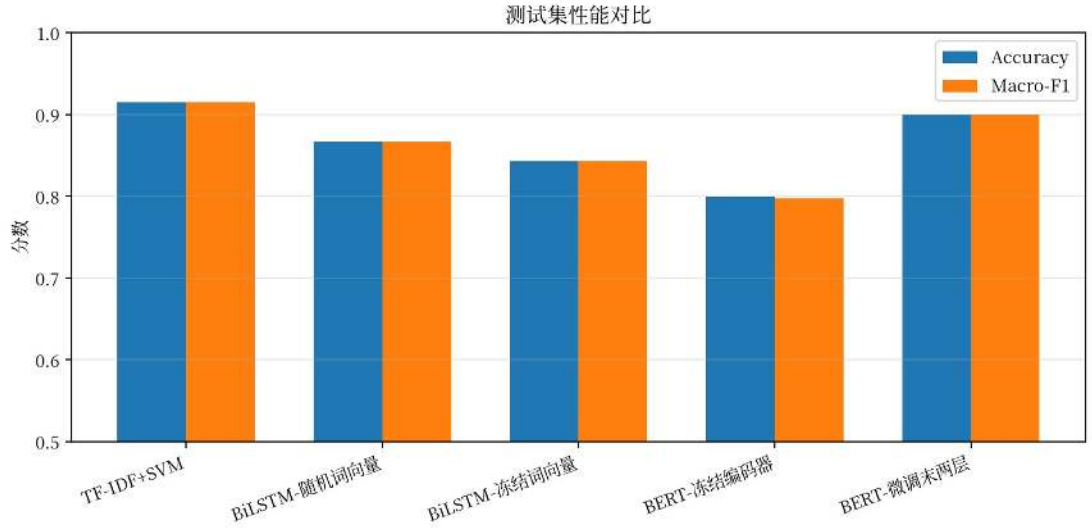


图 1 测试集 Accuracy 与 Macro-F1 对比

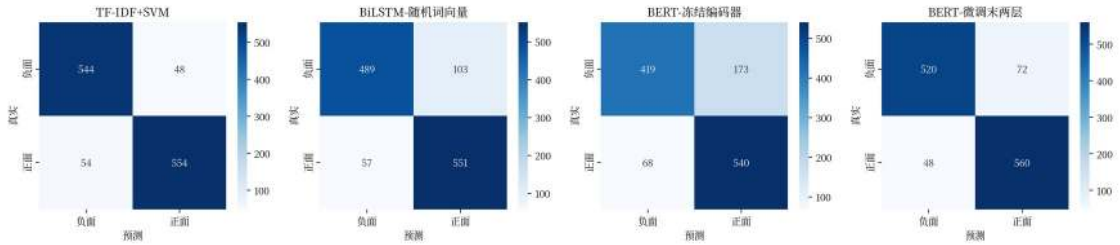


图 2 主要方法测试集混淆矩阵

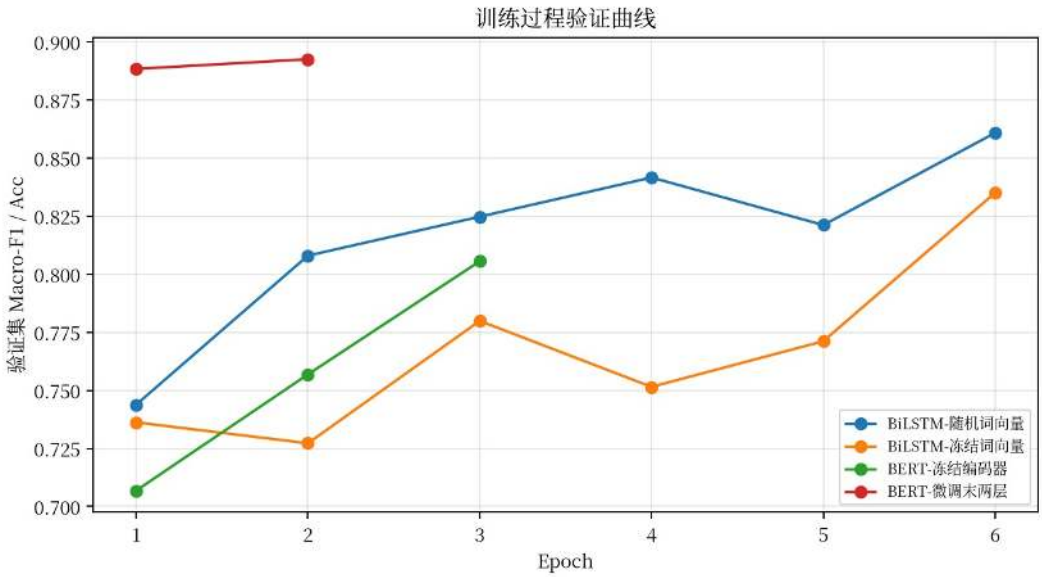


图 3 验证集训练曲线

测试集 Macro-F1 最高的是「TF-IDF+SVM」（91.50%）。TF-IDF+SVM 测试准确率 91.50%、Macro-F1 91.50%，在这个评论数据上意外地很能打。BiLSTM（词向量可训练）Macro-F1 是 86.63%；把词向量冻住以后掉到 84.30%，说明让嵌入跟着学还是有用的。 BERT 全冻住只有 79.71%；放开末两层微调后到 89.99%。

六、分析、思考与改进

先说 SVM 为什么不弱。这类评论里“脏”“差”“满意”“干净”本身就很冲，TF-IDF 一把就能抓住；BiLSTM 如果数据量和词向量都一般，不一定马上超过这个线性基线。所以强基线还是得留着。

消融这边：BiLSTM 让词向量跟着学，明显好过冻住；BERT 微调最后两层，也比纯冻结更贴任务。感觉就是：表示如果一点都不改，不一定比得过老老实实的词袋特征。

翻了些测试集错例。比如“这个宾馆比较陈旧了……总体来说一般”，标签是正的，模型常判负——口气偏平，没有很烈的褒义词。也有“3999 的时候抢购的……品牌和价格都很不错”这种，标签是负，句子里却一堆好话，可能标噪，或者缺上下文。还有一些装系统、改 BIOS 的操作说明混进来，跟情感关系不大，也会拖后腿。词袋和浅层序

列对转折句、噪声标签都还是挺敏感。以后如果有算力，可以换更大中文模型做全参微调，顺便清一清数据，或者做方面级情感。

局限也很清楚：我为了 CPU 能跑完，用的是轻量 rbt3，超参没有细搜，也没拿更大的 chinese-roberta-wwm-ext 之类做全量微调。条件允许的话，这些都可以再补。

七、结论

总的来说，这次把选题、数据、三种方法、对比消融和画图都跑通了。在这个数据集上，TF-IDF+SVM 依然很强；BiLSTM 靠可学习词向量能涨一点；小预训练模型冻住时一般，微调两层会好很多。代码和结果都在仓库里。

参考文献 / 资源

[1] ChnSentiCorp 数据集：https://huggingface.co/datasets/lansinuote/ChnSentiCorp

[2] HFL rbt3：https://huggingface.co/hfl/rbt3 （崔一鸣等，中文预训练模型系列）

[3] Pedregosa et al., Scikit-learn: Machine Learning in Python, JMLR, 2011.

[4] Hochreiter & Schmidhuber, Long Short-Term Memory, Neural Computation, 1997.

[5] Devlin et al., BERT: Pre-training of Deep Bidirectional Transformers, NAACL, 2019.

[6] 课程要求文档：《深度学习课程设计 2026-秋季》.